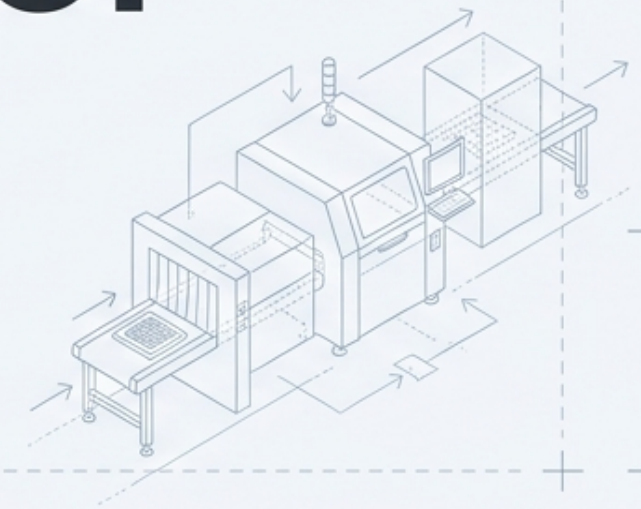
AI Second Opinion для Koh Young 3D AOI

Промышленный регламент внедрения каскадной системы арбитража дефектов



- Платформа: NVIDIA DGX Spark (128 GB Unified Memory)
- Модель: Gemma 4 26B-A4B-it (NVFP4)
- Инференс: vLLM (SM121 Optimized)

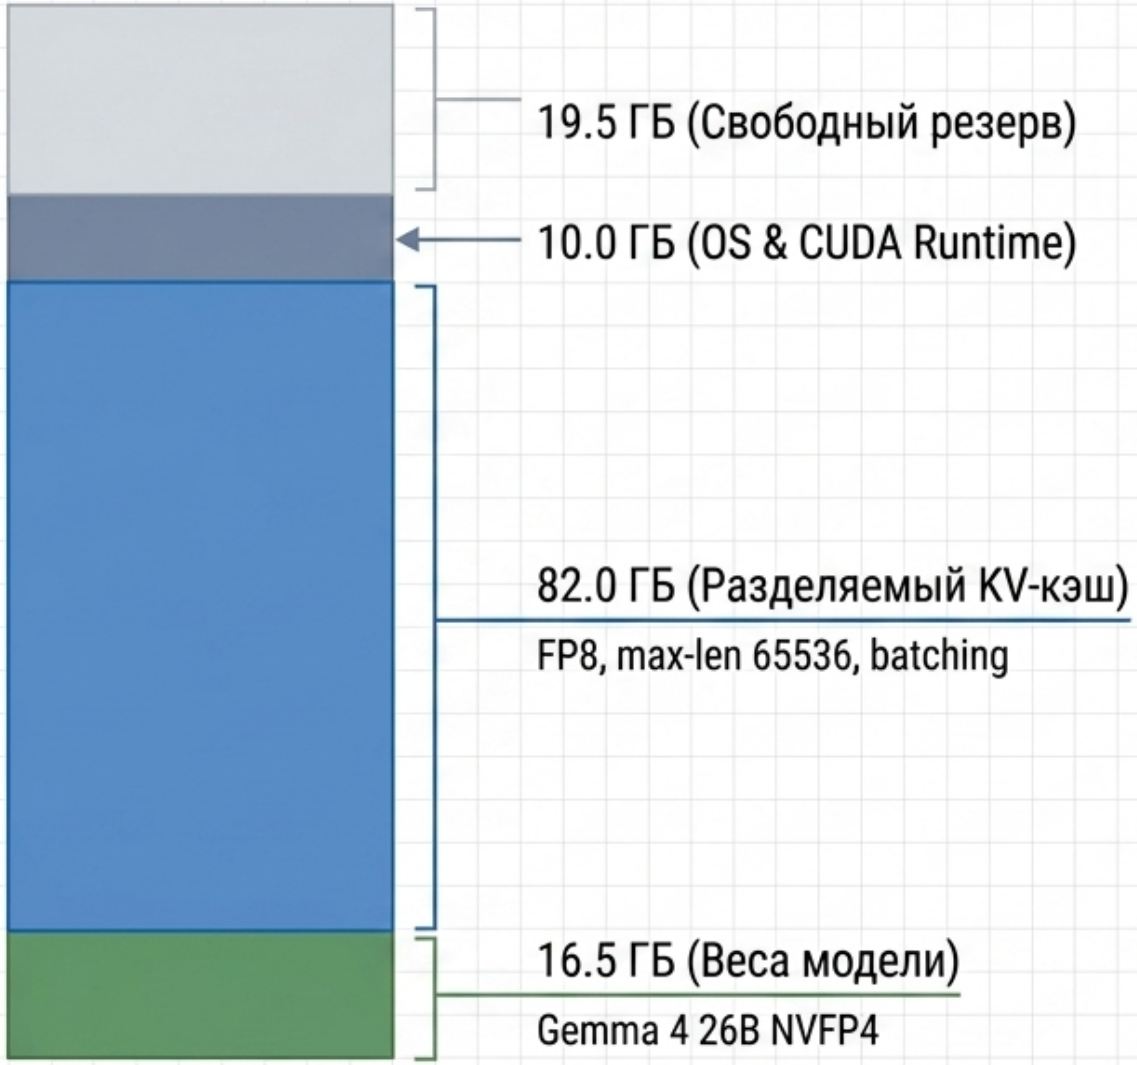
solaredge

Архитектура решения: Интеграция ИИ в производственный конвейер



ИИ действует как интеллектуальный арбитр в реальном времени, обеспечивая непрерывность SMT-линии и фильтруя до 99% ложных дефектов.

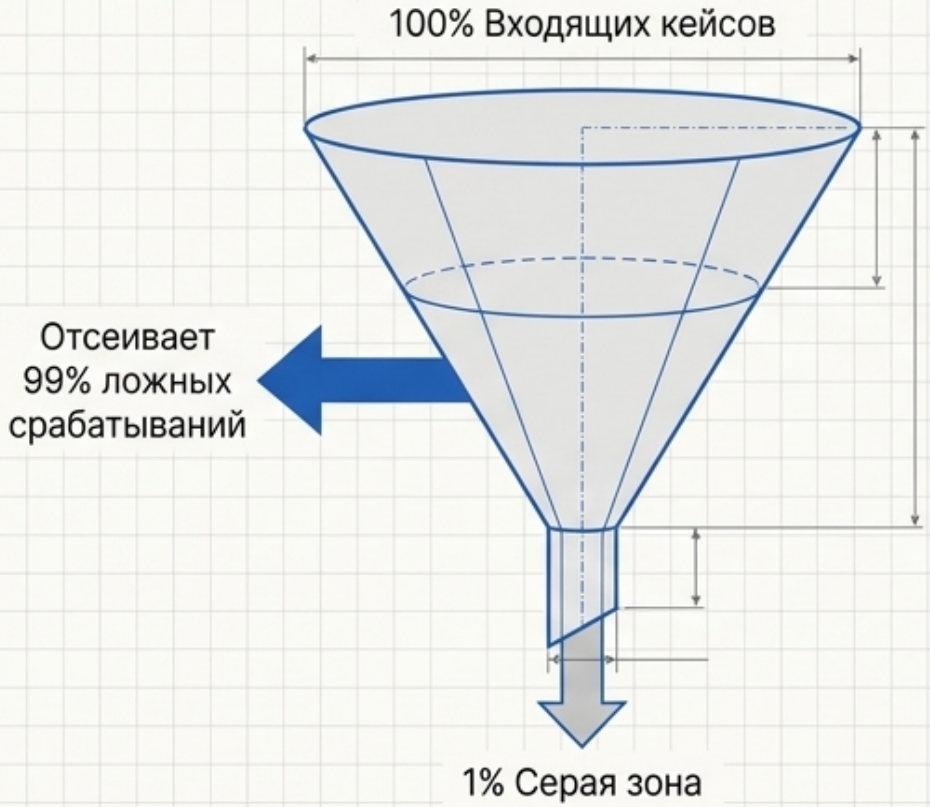
Аппаратный фундамент: Утилизация 128 GB Unified Memory




```
# Валидация платформы DGX Spark (GB10 / SM121)
uname -m                    # Ожидается: aarch64
nvidia-smi Unified Memory   # Ожидается: 128 ГБ
nvcc --version              # Ожидается: CUDA 13.0
```

⚠ Использование суперчипа Grace Blackwell требует ARM64-контейнера (nvcr.io/nvidia/pytorch:25.09-py3).

Двухуровневый каскад: Баланс скорости и точности



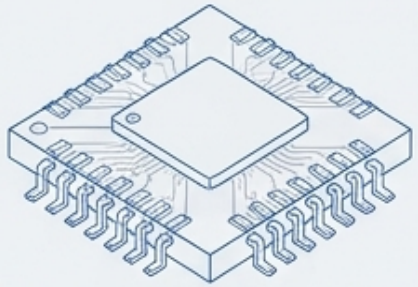
Параметр	Роль	Технология	Данные	Задержка
Tier-1 (Pre-filter)	Легковесный фильтр	XGBoost (CPU/GPU)	Табличные 3D-метрики	0 мс
Tier-2 (VLM)	Мультимодальный арбитраж	Gemma 4 26B (vLLM GB10)	Изображения + 3D + Нормы	Real-time

Разделение потока предотвращает перегрузку инференс-сервера, гарантируя пропускную способность SMT-линии.

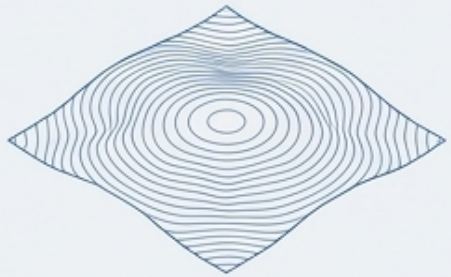
Анатомия инспекционного кейса

Visual Inputs

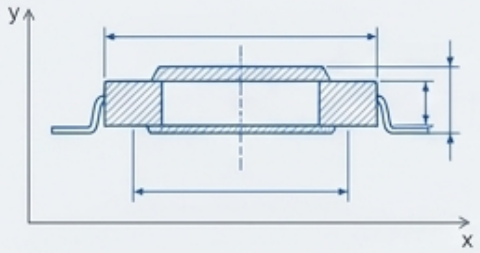
2D Color (2d_color.png)



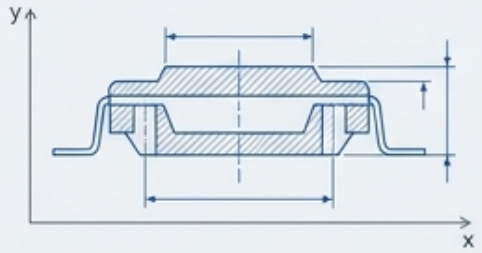
3D Height Map (3d_heightmap.png)



Cross Section A (slice_a.png)



Cross Section B (slice_b.png)



JSON payload

```
// metadata.json
{
  "case_id": "KY_20260803_001042",
  "component_type": "QFN-48",
  "defect_code": "INSUFFICIENT_SOLDER",
  "measured_3d_features": {
    "solder_volume_percentage": 38.5,
    "solder_height_um": 32.1,
    "coplanarity_error_um": 12.4
  }
}
```

Каждый кейс формируется как единый иммутабельный пакет, объединяющий визуальные паттерны и точные 3D-измерения галтели припоя.

Формирование Ground Truth и контроль качества данных

Архитектура Выборки (50/50 Класс-баланс)

Сплит	Минимальный объем	Оптимальный объем
Train	2 000 кейсов	10 000+ кейсов
Validation	500 кейсов	1 500 кейсов
Test Holdout	500 кейсов	1 000 кейсов

Оценка когерентности



Инференс-движок: Развертывание vLLM на SM121

```
export PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True

vllm serve models/gemma4-26b-nvfp4 \
    --quantization modelopt \
    --kv-cache-dtype fp8 \
    --max-model-len 65536 \
    --gpu-memory-utilization 0.85 \
    --moe-backend marlin \
    --reasoning-parser gemma4 \
    --limit-mm-per-prompt '{"image": 4}'
```

Критически важно для GB10. Прямое использование CUTLASS FP4 MoE без TMEM вызывает ошибки.

Жесткое резервирование мультимодальных слотов для 4 инспекционных изображений.

Мультимодальный RAG-слой: Контекстуализация стандартов



LLM не принимает решения в вакууме. Каждый вывод опирается на извлеченные стандарты и верифицированную историю.

Дерево принятия решений и изотоническая калибровка

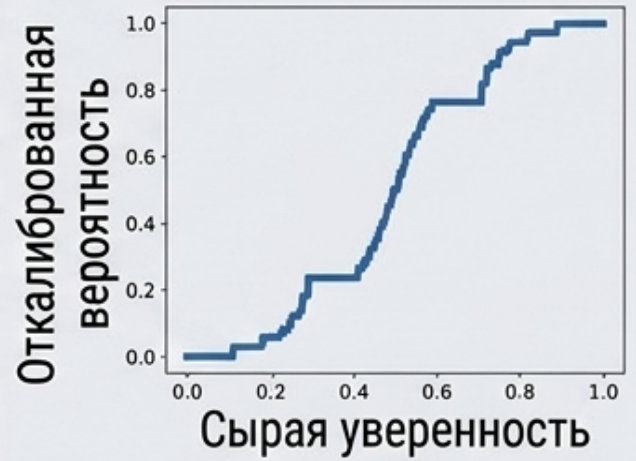
Входящий кейс → Расчет calibrated_confidence

≥ high_threshold → AUTO_VERDICT

low ≤ conf < high → Self-Consistency Check (5 сэмплов)

Self-Consistency Check (5 сэмплов):
- ≥ 4/5 совпадений → AUTO_VERDICT
- Разброс → Engineer Review

< low_threshold → Engineer Review



Пороги оптимизированы под целевой FNR ≤ 0.05%

$$P(Correct \mid S_{raw}) = f_{iso}(S_{raw})$$

Путь в Production: Безопасное внедрение

Фаза 1: Shadow Execution (2–4 недели)

- 100% потока SMT-линии.
- Вердикты пишутся в БД, конвейер не останавливается.
- Автоматическая сверка с решениями инженеров.

Фаза 2: Go-Live (Agreement Rate > 98%)

- Активация автоматического режима (`high_threshold`).
- Интеграция для мгновенного пропуска ложных срабатываний.

Фаза 3: Слепой Аудит (Первые 3 месяца)

- 15% решений скрыто перенаправляются на QA.
- Защита от дрейфа данных и галлюцинаций.

Мониторинг, Аудит-трейл и Триггеры отката

Журнал аудита (JSONL)


```
{
  "timestamp": "2026-08-03T15:04:12Z",
  "pipeline_tier": "tier2_vlm",
  "calibrated_confidence": 0.93,
  "final_action":
"AUTO_FALSE_POSITIVE",
  "reasoning_summary": "Solder height
below standard, but 2D view confirms
proper wetting across 85% of pad."
}
```


FNR > 0.05%

Превышение порога пропущенных дефектов за 7-дневное окно.

Эскалации > 30%

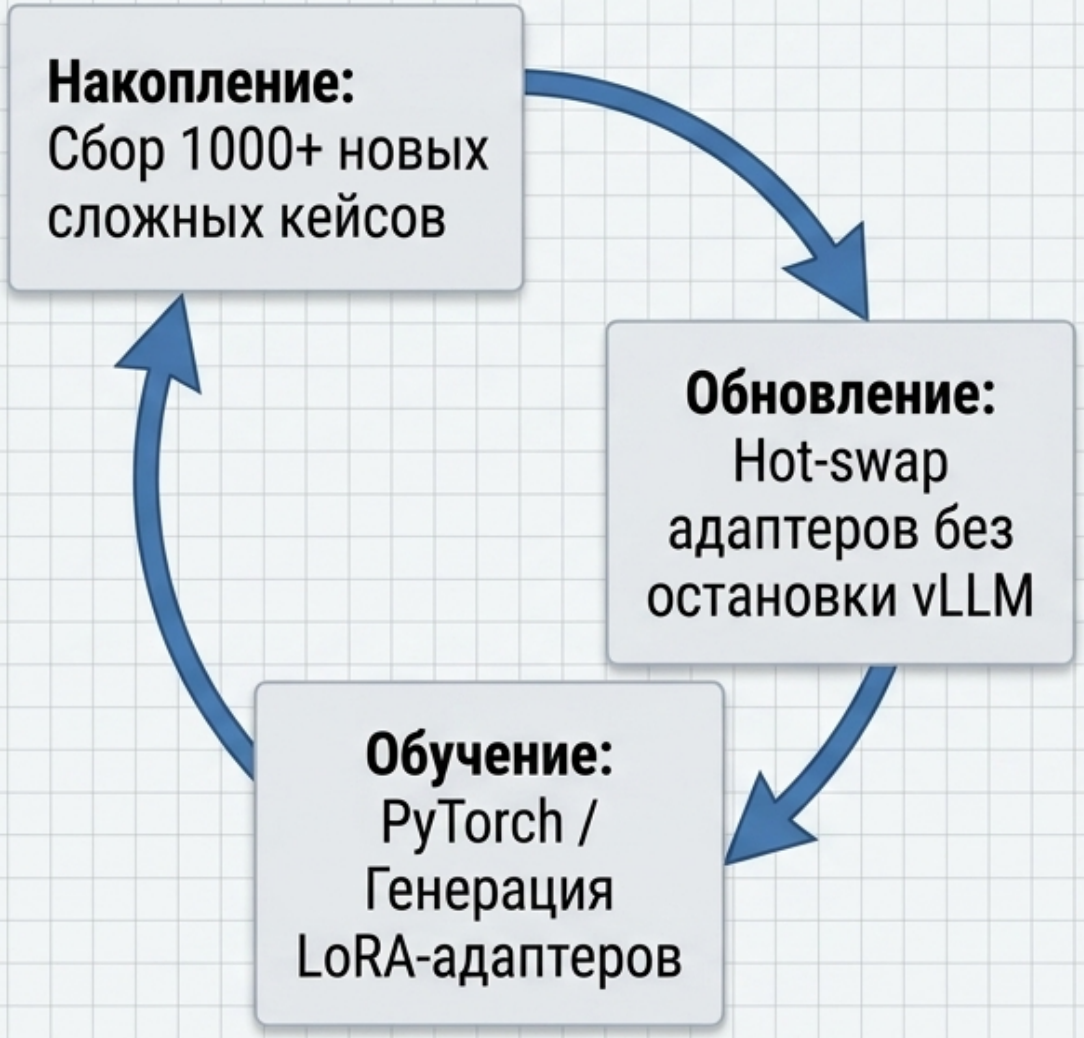
Рост неуверенных ответов нейросети, требующих ручной проверки.

Задержка p95 > 12 сек

Критическое падение производительности инференса.

Действие при триггере: Мгновенный переход в 100% ручной контроль.

Непрерывная эволюция: Локальное дообучение (QLoRA)




```
llamafactory-cli train \
  --finetuning_type lora \
  --quantization_bit 4 \
  --learning_rate 2e-4
```

Расход VRAM: 35–40 ГБ

Позволяет обучать модель прямо на заводском сервере (on-premise), оставляя 80+ ГБ для системных процессов.

Контрольный чек-лист готовности к Production

Инфраструктура и Инференс

- ✅ Окружение CUDA 13.0 и валидация GB10 пройдены.
- ✅ Сервер vLLM запущен (Marlin backend, порт 8000).
- ✅ Скорость инференса 26B NVFP4: 48–52 токена/с.

Данные и Логика

- ✅ Поток обогащен 3D-метриками от Koh Young.
- ✅ RAG-индекс загружен (IPC-A-610 + прецеденты).
- ✅ Пороги Isotonic Regression откалиброваны.

Безопасность и Аудит

- ✅ Фаза Shadow Execution пройдена (0% даун-тайма).
- ✅ Слепой аудит 15% решений настроен.
- ✅ Дашборды Grafana и иммутабельные логи активны.

СТАТУС: Проект валидирован. Система арбитража переведена в активный режим.