ПРОМЫШЛЕННЫЙ РЕГЛАМЕНТ

AI Second Opinion для Koh Young 3D AOI

Пошаговая инструкция по внедрению каскадной системы арбитража дефектов

Koh Young Case

Tier 1 XGBoost

Tier 2 VLM

Decision Engine

Численные признаки → визуальное подтверждение → калиброванное действие

МОДЕЛЬ	Gemma 4 26B-A4B-it · NVFP4
ПЛАТФОРМА	NVIDIA DGX Spark · GB10 · 128 GB Unified Memory
НАЗНАЧЕНИЕ	Контролируемая автоматизация разбора срабатываний AOI

Версия 1.0 · 03 августа 2026

Статус: проект регламента для валидации на производственной площадке

Содержание

Управление документом	3
0. Архитектурный обзор и предварительные требования	4
1. Валидация платформы DGX Spark	5
2. Принцип работы двухуровневого каскада	6
3. Сбор, структурирование и разметка данных	7
4. Структура датасета и разделение выборок	7
5. Настройка рабочей среды	8
6. Загрузка модели и развертывание vLLM	9
7. Мультимодальный промпт-инжиниринг и RAG	10
8. Логика принятия решений и калибровка	11
9. Shadow-режим, мониторинг и слепой аудит	12
10. Аудит-трейл и автоматический откат	13
11. Локальное тонкое обучение	13
12. Итоговый контрольный чек-лист	14
Приложение. Источники	14

Критические параметры

Показатель	Целевое значение
False Negative Rate	≤ 0,05%
Shadow Execution	2–4 недели
Слепой аудит	15% AUTO_VERDICT
Rollback по latency	p95 > 12 секунд

Управление документом

> Документ задаёт инженерную схему внедрения, но не заменяет квалификацию процесса, требования системы менеджмента качества, договорные обязательства и официальную интерпретацию IPC-A-610. Все версии модели, контейнеров, CLI-параметры, показатели производительности и лицензии должны быть подтверждены на целевой конфигурации до закупки и допуска в Production.

0. Архитектурный обзор — цель, границы и критерии готовности

Система реализует «второе мнение» для срабатываний Koh Young 3D AOI. Безопасная архитектура строится как каскад: быстрый фильтр численных признаков отсеивает только заведомо безопасные ложные срабатывания, мультимодальная модель рассматривает серую зону, а спорные случаи передаются инженеру.

0.1 Чек-лист предварительных требований

- Доступ к NVIDIA DGX Spark (GB10) с административными правами sudo.
- Аккаунт Hugging Face; приняты условия использования выбранной модели.
- Исторический архив дефектов Koh Young AOI за 6–12 месяцев.
- Не менее двух инженеров качества SMT для перекрёстной разметки.
- Утверждён целевой предел False Negative Rate: FNR ≤ 0,05%.
- Определены владелец риска, порядок остановки и ручной резервный процесс.

0.2 Ключевые принципы безопасности

1. Валидация платформы DGX Spark — GB10 · SM121 · CUDA 13.0

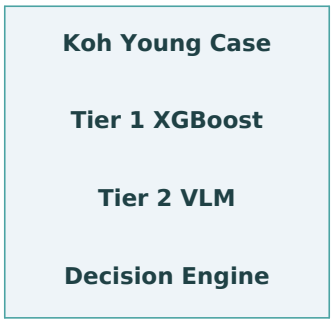
До развертывания зафиксируйте аппаратную конфигурацию, версии прошивки, драйвера, CUDA и контейнерного runtime. Результаты команд приложите к протоколу квалификации.

1.1 Контейнер NGC

> Контрольная точка: контейнер видит ускоритель, выполняет базовую CUDA-операцию, а каталог проекта доступен на запись. Тег контейнера перед эксплуатацией должен быть проверен в реестре NGC и закреплён digest-значением.

2. Принцип работы двухуровневого каскада

Предфильтр → мультимодальный арбитраж



Численные признаки → визуальное подтверждение → калиброванное действие

2.1 Tier-1 — фильтр табличных метрик

XGBoost анализирует объём припоя, высоту, копланарность и другие численные признаки. Кейс закрывается как AUTO_DISMISS только при доказанной вероятности ложного срабатывания выше 99% и при соблюдении ограничений применимости.

2.2 Tier-2 — мультимодальный арбитраж

Кейсы серой зоны поступают в VLM вместе с четырьмя изображениями, 3D-метриками, релевантными критериями IPC и проверенными прецедентами. Выход валидируется по JSON-схеме и проходит калибровку.

Матрица маршрутизации

3. Данные и Ground Truth — экспорт, разметка, согласованность

3. Сбор, структурирование и разметка данных

3.1 Пакет инспекционного кейса

- 2d_color.png — цветной вид сверху.
- 3d_heightmap.png — карта высот в условных цветах.
- slice_a.png и slice_b.png — поперечный и боковой срезы.
- metadata.json — идентификаторы, измерения AOI и технологический контекст.
- ground_truth.json — проверенный вердикт, код дефекта, комментарий и provenance разметки.

3.2 Ground Truth и когерентность

- Инженер назначает verdict: REAL_DEFECT или FALSE_POSITIVE, уточняет defect_code и добавляет обоснование.
- Для 15% выборки проводится независимая двойная разметка.
- Рассчитывается к Коэна; при к < 0,70 проводится калибровочная сессия.
- Спорные случаи получают hard_case: true и не используются для безусловной автоматизации до adjudication.
- Фиксируются идентификатор разметчика, версия стандарта, дата и итог согласования.

4. Структура датасета — временное разделение и баланс

4. Структура датасета и разделение выборок

Для обучения допускается баланс 50/50 REAL_DEFECT и FALSE_POSITIVE. Для оценки производственных KPI дополнительно используйте выборку с естественной распространённостью классов; иначе FNR, precision и нагрузка на инженеров будут искажены.

5. Настройка рабочей среды

Каталоги, venv, зависимости

В Production зависимости фиксируются lock-файлом и хешами; образы проходят сканирование уязвимостей. Секреты Hugging Face и сервисов не помещаются в репозиторий или audit-log.

6. Загрузка модели и развертывание vLLM

NVFP4 · Marlin · FP8 KV cache

6.1 Загрузка весов

6.2 Скрипт запуска scripts/start_gemma.sh

Параметры CLI зависят от конкретной версии vLLM и реализации модели. Перед запуском проверьте их по официальной документации установленной версии и зафиксируйте успешный smoke-test.

6.3 План памяти DGX Spark

Оценка памяти является проектным бюджетом, а не гарантией. Фактическое потребление измеряется при целевой длине контекста, числе изображений, batch size и параллельной нагрузке.

7. Мультимодальный промпт-инжиниринг и RAG

Строгая схема вывода и управляемый контекст

7.1 Системный промпт

7.2 Локальный RAG-слой

В Production рекомендуется отделить внутреннее рассуждение модели от краткого проверяемого обоснования. В журнал записываются наблюдаемые признаки, применённый критерий и ссылки на контекст — без скрытых chain-of-thought данных.

8. Логика принятия решений и калибровка

Пороги, self-consistency, isotonic regression

8.1 Матрица маршрутизации

8.2 Изотоническая калибровка

Калибратор преобразует сырой score S_raw в эмпирическую вероятность корректного ответа: P̂(Correct | S_raw) = f_iso(S_raw). Пороги выбираются на validation под ограничение FNR ≤ 0,05%, затем однократно подтверждаются на test holdout.

Для крайне низкого целевого FNR одной точечной оценки недостаточно: публикуйте доверительный интервал, число реальных дефектов в holdout и верхнюю границу риска. Если данных недостаточно, автоматический допуск не выдается.

9. Shadow-режим, мониторинг и слепой аудит

Наблюдение без воздействия на линию

9.1 Минимальный набор метрик

- FNR и доверительный интервал — в целом и по defect_code / component_type.
- Agreement rate, precision, recall, escalation rate и доля OOD.
- Latency p50/p95/p99, throughput, ошибки JSON и таймауты.
- Data drift по численным признакам, линиям, продуктам и источникам изображений.
- Доля решений, изменённых инженером, и причины override.

10. Аудит-трейл и автоматический откат

Неизменяемый журнал и безопасный откат

10.1 Триггеры rollback

- FNR > 0,05% по слепому аудиту за скользящее окно 7 дней.
- Engineer Review > 30% общего потока.
- Latency p95 > 12 секунд.
- Невалидный JSON, недоступный RAG или несоответствие версии модели утверждённой конфигурации.
- Обнаруженный класс критического пропуска, даже если агрегированный FNR остаётся в лимите.

> Действие по умолчанию: немедленный переход в 100% ручной контроль, фиксация инцидента, уведомление владельца процесса, анализ первопричины и повторная квалификация перед возвратом.

11. Локальное дообучение — QLoRA в окне обслуживания

11. Локальное тонкое обучение

После накопления не менее 1 000 новых сложных adjudicated-кейсов допускается обучение LoRA-адаптера. Обучающий набор отделяется от validation и temporal holdout; базовая модель, данные и параметры получают версии.

Проектная оценка памяти QLoRA: 35–40 GB. Она должна быть подтверждена экспериментом. Новая версия не заменяет действующую без полного regression-test, перекалибровки и повторного Shadow Execution.

12. Итоговый контрольный чек-лист

Production readiness — финальный допуск

- CUDA 13.0 и GB10 валидированы в закреплённом NGC-контейнере.
- vLLM успешно запущен на порту 8000; backend и все параметры подтверждены на установленной версии.
- Производительность одиночного инференса измерена; целевой ориентир 48–52 токена/с подтверждён или скорректирован протоколом.
- Поток содержит структурированные 3D-метрики Koh Young и проходит schema validation.
- RAG-индекс содержит актуальные разрешённые чанки IPC-A-610 и проверенные прецеденты.
- Isotonic Regression выполнена; high_threshold и low_threshold утверждены и версионированы.
- Shadow Execution пройдена 2–4 недели без критических сбоев.
- Слепой аудит 15% автоматических решений активен.
- Неизменяемый audit trail, алерты и Grafana-мониторинг работают 24/7.
- Rollback проверен учением; ручной резервный процесс доступен.
- Комитет качества подписал протокол допуска с ограничениями по классам и линиям.

12.1 Матрица решения Go / No-Go

Приложение. Источники

Ссылки ниже перенесены из исходного материала. Перед утверждением регламента необходимо проверить доступность, дату публикации, авторитетность и соответствие фактически используемым версиям ПО и оборудования.

- Gemma 4 Day-1 Inference on NVIDIA DGX Spark — Preliminary Benchmarks — forums.developer.nvidia.com
- [Benchmark] Gemma 4 on DGX Spark — Which Model Should You Pick? — ai-muninn — ai-muninn.com
- Google/gemma-4-26B-A4B-it — vLLM Recipes — recipes.vllm.ai
- An Analytical Report on the NVIDIA DGX Spark — TWOWIN TECHNOLOGY — twowintech.com
- Google Gemma 4: Smooth local inference on RTX PCs and DGX Spark — migovi.com
- Fine-tuning LLMs with NVIDIA DGX Spark and Unsloth — unsloth.ai

Конец документа · AI Second Opinion для Koh Young 3D AOI · Версия 1.0