ПРОМЫШЛЕННЫЙ РЕГЛАМЕНТ

AI Second Opinion для Koh Young 3D AOI

Пошаговая инструкция по внедрению каскадной системы арбитража дефектов



Численные признаки → визуальное подтверждение → калиброванное действие

МОДЕЛЬ	**Gemma 4 26B-A4B-it · NVFP4**
ПЛАТФОРМА	**NVIDIA DGX Spark · GB10 · 128 GB Unified Memory**
НАЗНАЧЕНИЕ	**Контролируемая автоматизация разбора срабатываний AOI**

Версия 1.0
03 августа 2026

Статус: проект регламента для валидации на производственной площадке

Содержание

Содержание	2
Управление документом	3
0. Архитектурный обзор и предварительные требования	3
1. Валидация платформы DGX Spark	4
2. Принцип работы двухуровневого каскада	5
3. Сбор, структурирование и разметка данных	6
4. Структура датасета и разделение выборок	7
5. Настройка рабочей среды	7
6. Загрузка модели и развертывание vLLM	8
7. Мультимодальный промпт-инжиниринг и RAG	9
8. Логика принятия решений и калибровка	10
9. Shadow-режим, мониторинг и слепой аудит	11
10. Аудит-трейл и автоматический откат	12
11. Локальное тонкое обучение	13
12. Итоговый контрольный чек-лист	13
Приложение. Источники	14

Критические параметры

Показатель	Целевое значение
False Negative Rate	≤ 0,05%
Shadow Execution	2–4 недели
Слепой аудит	15% AUTO_VERDICT
Rollback no latency	p95 > 12 секунд

Управление документом

Параметр	Значение
Класс документа	Технический регламент внедрения
Область применения	SMT-линии с Koh Young 3D AOI
Владелец процесса	Руководитель качества SMT / Process Owner
Критичность	Высокая: решение влияет на выпуск и ручной контроль
Период пересмотра	Ежеквартально и после каждого изменения модели, порогов или IPC-контекста

ВАЖНО
Документ задаёт инженерную схему внедрения, но не заменяет квалификацию процесса, требования системы менеджмента качества, договорные обязательства и официальную интерпретацию IPC-A-610. Все версии модели, контейнеров, CLI-параметры, показатели производительности и лицензии должны быть подтверждены на целевой конфигурации до закупки и допуска в Production.

0 **Архитектурный обзор**
Цель, границы и критерии готовности

0. Архитектурный обзор и предварительные требования

Система реализует «второе мнение» для срабатываний Koh Young 3D AOI. Безопасная архитектура строится как каскад: быстрый фильтр численных признаков отсеивает только заведомо безопасные ложные срабатывания, мультимодальная модель рассматривает серую зону, а спорные случаи передаются инженеру.

0.1 Чек-лист предварительных требований

- ☐ Доступ к NVIDIA DGX Spark (GB10) с административными правами sudo.
- ☐ Аккаунт Hugging Face; приняты условия использования выбранной модели.
- ☐ Исторический архив дефектов Koh Young AOI за 6–12 месяцев.
- ☐ Не менее двух инженеров качества SMT для перекрёстной разметки.
- ☐ Утверждён целевой предел False Negative Rate: FNR ≤ 0,05%.

- [ ] Определены владелец риска, порядок остановки и ручной резервный процесс.

0.2 Ключевые принципы безопасности

Принцип	Практическая реализация
Human-in-the-loop	Низкая уверенность и несогласованные ответы — только Engineer Review.
Fail-safe	При деградации метрик — возврат к 100% ручному контролю.
Traceability	Версии модели, промпта, RAG-контекста и решение фиксируются в аудите.
Temporal validation	Финальная проверка выполняется на более позднем временном холдауте.
Least automation	Автоматизируются только классы и диапазоны, доказавшие безопасность.

1 **Валидация DGX Spark**

GB10 · SM121 · CUDA 13.0

1. Валидация платформы DGX Spark

До развертывания зафиксируйте аппаратную конфигурацию, версии прошивки, драйвера, CUDA и контейнерного runtime. Результаты команд приложите к протоколу квалификации.

```
uname -m                # ожидается: aarch64
nvidia-smi              # GB10 и доступная unified memory
nvcc --version          # целевая версия: CUDA 13.0
```

1.1 Контейнер NGC

```
docker pull nvcr.io/nvidia/pytorch:25.09-py3

docker run --gpus all -it --rm \
  --ipc=host \
  --ulimit memlock=-1 \
  -v ~/aoi_project:/workspace \
  nvcr.io/nvidia/pytorch:25.09-py3
```

Контрольная точка: контейнер видит ускоритель, выполняет базовую CUDA-операцию, а каталог проекта доступен на запись. Тег контейнера перед эксплуатацией должен быть проверен в реестре NGC и закреплён digest-значением.

2 **Двухуровневый каскад**

Предфильтр → мультимодальный арбитраж

2. Принцип работы двухуровневого каскада



Численные признаки → визуальное подтверждение → калиброванное действие

2.1 Tier-1 — фильтр табличных метрик

XGBoost анализирует объём припоя, высоту, копланарность и другие численные признаки. Кейс закрывается как AUTO_DISMISS только при доказанной вероятности ложного срабатывания выше 99% и при соблюдении ограничений применимости.

2.2 Tier-2 — мультимодальный арбитраж

Кейсы серой зоны поступают в VLM вместе с четырьмя изображениями, 3D-метриками, релевантными критериями IPC и проверенными прецедентами. Выход валидируется по JSON-схеме и проходит калибровку.

Маршрут	Условие	Действие
AUTO_DISMISS	Tier-1: строго безопасная область	Закрыть с полным audit trail
AUTO_VERDICT	Tier-2: высокая calibrated confidence	Применить решение; включить в слепой аудит
ENGINEER_REVIEW	Низкая уверенность / конфликт / OOD	Передать инженеру
SAFE MODE	Ошибка сервиса или rollback-trigger	100% ручной контроль

3 **Данные и Ground Truth**

Экспорт, разметка, согласованность

3. Сбор, структурирование и разметка данных

3.1 Пакет инспекционного кейса

- 2d_color.png — цветной вид сверху.
- 3d_heightmap.png — карта высот в условных цветах.
- slice_a.png и slice_b.png — поперечный и боковой срезы.
- metadata.json — идентификаторы, измерения AOI и технологический контекст.
- ground_truth.json — проверенный вердикт, код дефекта, комментарий и provenance разметки.

```
{
  "case_id": "KY_20260803_001042",
  "component_type": "QFN-48",
  "part_number": "PN-100429-B",
  "line_id": "SMT_LINE_02",
  "defect_code": "INSUFFICIENT_SOLDER",
  "koh_young_confidence": 0.82,
  "measured_3d_features": {
    "solder_volume_percentage": 38.5,
    "solder_height_um": 32.1,
    "coplanarity_error_um": 12.4,
    "ipc_spec_min_height_um": 50.0
  },
  "timestamp": "2026-08-03T14:22:10Z"
}
```

3.2 Ground Truth и когерентность

- Инженер назначает verdict: REAL_DEFECT или FALSE_POSITIVE, уточняет defect_code и добавляет обоснование.
- Для 15% выборки проводится независимая двойная разметка.
- Рассчитывается к Коэна; при к < 0,70 проводится калибровочная сессия.
- Спорные случаи получают hard_case: true и не используются для безусловной автоматизации до adjudication.
- Фиксируются идентификатор разметчика, версия стандарта, дата и итог согласования.

4 **Структура датасета**

Временное разделение и баланс

4. Структура датасета и разделение выборок

```
dataset/
├── train/2026-01/case_000001/
│   ├── 2d_color.png
│   ├── 3d_heightmap.png
│   ├── slice_a.png
│   ├── slice_b.png
│   ├── metadata.json
│   └── ground_truth.json
├── val/2026-02/
└── test_holdout/2026-06/    # не участвует в обучении
```

Выборка	Минимум	Целевой объём	Назначение
Train	2 000	10 000+	Обучение / настройка
Validation	500	1 500	Калибровка и пороги
Test Holdout	500	1 000	Финальная независимая оценка

Для обучения допускается баланс 50/50 REAL_DEFECT и FALSE_POSITIVE. Для оценки производственных KPI дополнительно используйте выборку с естественной распространённостью классов; иначе FNR, precision и нагрузка на инженеров будут искажены.

5 **Рабочая среда**

Каталоги, venv, зависимости

5. Настройка рабочей среды

```
mkdir -p ~/aoi_project/{models,dataset,calibration,results,audit,monitoring,
logs,prompts,scripts,training,vector_db}
cd ~/aoi_project

python3 -m venv venv
source venv/bin/activate
pip install -U pip
pip install torch transformers vllm openai numpy pandas scikit-learn \
  opencv-python pillow qdrant-client sentence-transformers
pip install -U 'huggingface_hub[cli]'
```

В Production зависимости фиксируются lock-файлом и хешами; образы проходят сканирование уязвимостей. Секреты Hugging Face и сервисов не помещаются в репозиторий или audit-log.

6 **Модель и vLLM**

NVFP4 · Marlin · FP8 KV cache

6. Загрузка модели и развертывание vLLM

6.1 Загрузка весов

```
huggingface-cli login

huggingface-cli download nvidia/Gemma-4-26B-A4B-NVFP4 \
  --local-dir models/gemma4-26b-nvfp4
```

6.2 Скрипт запуска scripts/start_gemma.sh

```
#!/bin/bash
set -euo pipefail
export PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True

vllm serve models/gemma4-26b-nvfp4 \
  --served-model-name gemma-4-26b \
  --host 0.0.0.0 --port 8000 \
  --quantization modelopt \
  --kv-cache-dtype fp8 \
  --max-model-len 65536 \
  --gpu-memory-utilization 0.85 \
  --moe-backend marlin \
  --reasoning-parser gemma4 \
  --enable-auto-tool-choice \
  --tool-call-parser pythonic \
  --max-num-batched-tokens 8192 \
  --limit-mm-per-prompt '{"image": 4}'
```

Параметры CLI зависят от конкретной версии vLLM и реализации модели. Перед запуском проверьте их по официальной документации установленной версии и зафиксируйте успешный smoke-test.

6.3 План памяти DGX Spark

Потребитель	Оценка	Доля от 128 GB
Веса NVFP4	≈ 16,5 GB	12,9%
KV-cache FP8 / batching	≈ 82,0 GB	64,1%
ОС и CUDA Runtime	≈ 10,0 GB	7,8%
Свободный резерв	≈ 19,5 GB	15,2%
Итого	128,0 GB	100%

Оценка памяти является проектным бюджетом, а не гарантией. Фактическое потребление измеряется при целевой длине контекста, числе изображений, batch size и параллельной нагрузке.

7 **Промпт и RAG**

Строгая схема вывода и управляемый контекст

7. Мультимодальный промпт-инжиниринг и RAG

7.1 Системный промпт

```
You are an expert SMT Quality Control Arbiter adhering strictly to
IPC-A-610 standards. You receive measured 3D features, relevant
acceptance criteria, verified precedents, and exactly four images.

Analyze physical 3D metrics first, then cross-examine visual evidence.
Return STRICT JSON only:
{
  "verdict": "REAL_DEFECT" | "FALSE_POSITIVE",
  "confidence": 0.0-1.0,
  "defect_code": "...",
  "reasoning": "..."
}
```

7.2 Локальный RAG-слой

Индекс	Запрос	Выход	Контроль
Precedents DB	Описание + метаданные	3 похожих кейса	Только adjudicated GT
IPC / Manuals	defect_code + component_type	Релевантные чанки	Версия, раздел, лицензия

В Production рекомендуется отделить внутреннее рассуждение модели от краткого проверяемого обоснования. В журнал записываются наблюдаемые признаки, применённый критерий и ссылки на контекст — без скрытых chain-of-thought данных.

8 **Решения и калибровка**

Пороги, self-consistency, isotonic regression

8. Логика принятия решений и калибровка

8.1 Матрица маршрутизации

Условие	Маршрут	Обязательный контроль
Tier-1 FP confidence > 0,99	AUTO_DISMISS	Guardrails + OOD + аудит
calibrated confidence ≥ high_threshold	AUTO_VERDICT	Слепой аудит 15%
low ≤ confidence < high	5 сэмплов, T=0,7	Согласие ≥ 4/5; иначе review
confidence < low_threshold	ENGINEER_REVIEW	Ручной вердикт
Ошибка / drift / rollback	SAFE MODE	100% ручной контроль

8.2 Изотоническая калибровка

Калибратор преобразует сырой score S_raw в эмпирическую вероятность корректного ответа: P(Correct | S_raw) = f_iso(S_raw). Пороги выбираются на validation под ограничение FNR ≤ 0,05%, затем однократно подтверждаются на test holdout.

```
import glob, json
from sklearn.isotonic import IsotonicRegression

raw_conf, labels = [], []
for filepath in glob.glob("results/val/*.json"):
    with open(filepath, encoding="utf-8") as fh:
        data = json.load(fh)
    raw_conf.append(data["raw_confidence"])
    labels.append(int(data["verdict"] == data["ground_truth"]))

iso_model = IsotonicRegression(out_of_bounds="clip")
iso_model.fit(raw_conf, labels)
# Далее: выбор порогов с доверительным интервалом для FNR.
```

Для крайне низкого целевого FNR одной точечной оценки недостаточно: публикуйте доверительный интервал, число реальных дефектов в holdout и верхнюю границу риска. Если данных недостаточно, автоматический допуск не выдается.

9 **Shadow и аудит**

Наблюдение без воздействия на линию

9. Shadow-режим, мониторинг и слепой аудит

Фаза	Срок / охват	Критерий выхода
Shadow Execution	2–4 недели; 100% потока	Стабильность, latency, класс-метрики, no critical misses
Ограниченный Production	Только валидированные классы	Agreement > 98% и FNR в лимите
Слепой аудит	15% AUTO_VERDICT первые 3 месяца	Независимая проверка без показа AI-ответа

9.1 Минимальный набор метрик

- FNR и доверительный интервал — в целом и по defect_code / component_type.
- Agreement rate, precision, recall, escalation rate и доля OOD.
- Latency p50/p95/p99, throughput, ошибки JSON и таймауты.
- Data drift по численным признакам, линиям, продуктам и источникам изображений.
- Доля решений, изменённых инженером, и причины override.

10 **Аудит и rollback**

Неизменяемый журнал и безопасный откат

10. Аудит-трейл и автоматический откат

```
{
  "timestamp": "2026-08-03T15:04:12Z",
  "case_id": "KY_20260803_001042",
  "pipeline_tier": "tier2_vlm",
  "model_version": "gemma-4-26b-a4b-nvfp4-v1",
  "raw_confidence": 0.96,
  "calibrated_confidence": 0.93,
  "final_action": "AUTO_FALSE_POSITIVE",
  "reasoning_summary": "Observed metrics and visual evidence...",
  "retrieved_context_ids": {
    "precedents": ["case_000412", "case_001899"],
    "ipc_section": "ipc_a_610_h_sec8_3_5"
  }
}
```

10.1 Триггеры rollback

- FNR > 0,05% по слепому аудиту за скользящее окно 7 дней.
- Engineer Review > 30% общего потока.
- Latency p95 > 12 секунд.
- Невалидный JSON, недоступный RAG или несоответствие версии модели утверждённой конфигурации.
- Обнаруженный класс критического пропуска, даже если агрегированный FNR остаётся в лимите.

Действие по умолчанию: немедленный переход в 100% ручной контроль, фиксация инцидента, уведомление владельца процесса, анализ первопричины и повторная квалификация перед возвратом.

11 **Локальное дообучение**

QLoRA в окне обслуживания

11. Локальное тонкое обучение

После накопления не менее 1 000 новых сложных adjudicated-кейсов допускается обучение LoRA-адаптера. Обучающий набор отделяется от validation и temporal holdout; базовая модель, данные и параметры получают версии.

```
llamafactory-cli train \
  --stage sft --do_train \
  --model_name_or_path models/gemma4-26b-nvfp4 \
  --dataset koh_young_fine_tuning_data \
  --template gemma4 \
  --finetuning_type lora --lora_target all \
  --output_dir output/gemma4_aoi_lora_v2 \
  --per_device_train_batch_size 1 \
  --gradient_accumulation_steps 8 \
  --learning_rate 2e-4 --num_train_epochs 3 \
  --quantization_bit 4
```

Проектная оценка памяти QLoRA: 35–40 GB. Она должна быть подтверждена экспериментом. Новая версия не заменяет действующую без полного regression-test, перекалибровки и повторного Shadow Execution.

12 **Production readiness**

Финальный допуск

12. Итоговый контрольный чек-лист

- ☐ CUDA 13.0 и GB10 валидированы в закреплённом NGC-контейнере.
- ☐ vLLM успешно запущен на порту 8000; backend и все параметры подтверждены на установленной версии.
- ☐ Производительность одиночного инференса измерена; целевой ориентир 48–52 токена/с подтверждён или скорректирован протоколом.
- ☐ Поток содержит структурированные 3D-метрики Koh Young и проходит schema validation.
- ☐ RAG-индекс содержит актуальные разрешённые чанки IPC-A-610 и проверенные прецеденты.
- ☐ Isotonic Regression выполнена; high_threshold и low_threshold утверждены и версионированы.
- ☐ Shadow Execution пройдена 2–4 недели без критических сбоев.
- ☐ Слепой аудит 15% автоматических решений активен.
- ☐ Неизменяемый audit trail, алерты и Grafana-мониторинг работают 24/7.

- ☐ Rollback проверен учением; ручной резервный процесс доступен.
- ☐ Комитет качества подписал протокол допуска с ограничениями по классам и линиям.

12.1 Матрица решения Go / No-Go

Область	GO	NO-GO
Безопасность	FNR и верхняя граница CI в лимите	Недостаточно дефектов или critical miss
Качество данных	Полнота, provenance, κ ≥ 0,70	Утечки, пропуски, несогласованная разметка
Надёжность	SLA и rollback проверены	Нет safe mode / таймауты
Управление	Версии и владельцы зафиксированы	Нет владельца риска или аудита

Приложение. Источники

Ссылки ниже перенесены из исходного материала. Перед утверждением регламента необходимо проверить доступность, дату публикации, авторитетность и соответствие фактически используемым версиям ПО и оборудования.

1. Gemma 4 Day-1 Inference on NVIDIA DGX Spark — Preliminary Benchmarks
forums.developer.nvidia.com

2. [Benchmark] Gemma 4 on DGX Spark — Which Model Should You Pick? — ai-muninn
ai-muninn.com

3. Google/gemma-4-26B-A4B-it — vLLM Recipes
recipes.vllm.ai

4. An Analytical Report on the NVIDIA DGX Spark — TWOWIN TECHNOLOGY
twowintech.com

5. Google Gemma 4: Smooth local inference on RTX PCs and DGX Spark
migovi.com

6. Fine-tuning LLMs with NVIDIA DGX Spark and Unsloth
unsloth.ai

Конец документа · AI Second Opinion для Koh Young 3D AOI · Версия 1.0